

Caso de estudio 1:
Optimización en la predicción del consumo eléctrico en España (2015-2018)

Universidad de Santiago, Departamento de Ingeniería Industrial

Estudiantes:
Antonia Carvajal
Cristian Ramos
Amanda Toro
Martina Pinto
Héctor Ortiz

Profesor: Luis Rojo y Francisco Gomez
Asignatura: Estadística Aplicada



Resumen ejecutivo

Se pronostica la demanda eléctrica horaria en España a 24 horas de anticipación utilizando registros históricos del periodo 2015-2018 (34.866 observaciones utilizables). Se evaluaron modelos lineales, regularizados (Ridge, Lasso, Elastic-Net), GAM (splines) y ensembles (Árboles, Random Forest, Boosting y Averaging) mediante validación cruzada temporal en 4 bloques crecientes. El modelo Random Forest (con 3 variables por corte) fue seleccionado como el sistema definitivo aplicando la regla de parsimonia. En la apertura única del conjunto de prueba (año 2018), el Random Forest alcanzó un error cuadrático medio (RMSE) de 2.361 MW (error absoluto medio de 1.642 MW y R^2 de 0,740), representando una mejora del 16,4% en la precisión respecto al modelo de referencia o baseline (RMSE de 2.826 MW). En días no laborables el error aumentó a 2.709 MW. El intervalo de predicción empírico al 95% obtuvo una cobertura real del 95,2%.

1. Problema, datos y disponibilidad temporal

El objetivo del proyecto es optimizar la programación y despacho de la generación eléctrica en el sistema español con 24 horas de anticipación. La unidad de análisis corresponde a una hora individual del sistema y la variable respuesta es la demanda real consumida expresada en megavatios (MW).

Se procesaron 35.064 horas (filas) provenientes de la plataforma ENTSO-E y Red Eléctrica de España (2015-2018). La auditoría reveló 36 datos faltantes en la demanda, los cuales fueron descartados mediante eliminación completa por tratarse de la variable respuesta. Para evitar estrictamente la fuga de información (leakage), no se utilizó ninguna variable de generación contemporánea de la misma hora. Solo se emplearon variables del calendario (hora, día de la semana, día del año y festivos nacionales) y variables del pasado con un rezago igual o superior a 24 horas (demanda de hace 24 horas, demanda de hace una semana, promedio móvil de 24 horas y generaciones previas por fuente).

La Figura B1 (Anexo B) muestra por qué se incluyeron las variables de calendario. La demanda promedio llega a su mínimo cerca de las 04:00 horas, sube con fuerza entre las 06:00 y las 10:00 horas y tiene dos máximos: entre las 11:00 y las 13:00 horas y entre las 20:00 y las 21:00 horas. Entre las 08:00 y las 20:00 horas, los días no laborables consumen en promedio unos 3.500 MW menos que los laborables, mientras que de madrugada la diferencia es menor a 1.200 MW. Por eso la hora y el tipo de día entran como predictores y, en el modelo lineal, también su interacción.



2. Relaciones e inferencia

Con el conjunto de entrenamiento (años 2015 a 2017, con 26.108 observaciones), el modelo de Regresión Lineal (OLS) alcanzó un coeficiente de determinación R cuadrado de 0,696.

- Demanda de hace 24 horas (demanda_lag24): Presentó un coeficiente estimado de 0,290 (con un valor p menor a 2×10^{-16}). Incrementar en 1 desviación estándar esta variable (4.541 MW) aumenta la demanda predicha en 1.317 MW (un 4,61% respecto a la demanda media). Esto demuestra una alta significancia estadística acompañada de una alta relevancia práctica.
- Precio de hace 24 horas (precio_lag24): Presentó un coeficiente de 10,8 (con un valor p de $2,29 \times 10^{-10}$). Sin embargo, incrementar en 1 desviación estándar el precio (14,2 €/MWh) solo impacta la demanda en 153 MW (apenas un 0,54% de la demanda media), presentando además un intervalo de confianza al 95% por bootstrap de [-3,23 ; 21,70] que incluye el cero. Esto evidencia un claro caso de significancia estadística artificial provocada por un gran tamaño muestral, pero sin relevancia práctica ni operativa.

Diagnóstico de supuestos OLS y pruebas formales: Los residuos mostraron una fuerte autocorrelación a 1 hora de rezago ($r = 0,96$). Las pruebas formales de Breusch-Pagan (heterocedasticidad, $p < 0,001$), Durbin-Watson y Ljung-Box (autocorrelación residual, $p < 0,001$) rechazaron los supuestos clásicos del OLS, lo que invalida los intervalos de confianza teóricos y justifica el uso del método bootstrap por bloques diarios para estimar la incertidumbre real. La distancia de Cook máxima fue de apenas 0,0015 (sin observaciones influyentes) y todos los factores de inflación de varianza (VIF) se mantuvieron por debajo de 3,8, descartando problemas de multicolinealidad severa.

La Figura B2 muestra estos diagnósticos. En el panel de escala-ubicación la línea roja sube de 0,5 a 0,8: la dispersión de los residuos crece con el nivel de la demanda, lo que concuerda con la heterocedasticidad detectada. En el gráfico Q-Q los puntos se alejan de la recta en ambos extremos, señal de colas más pesadas que las de una distribución normal, y en el panel de residuos contra apalancamiento ningún punto se acerca a las curvas de distancia de Cook. La Figura B3 muestra la autocorrelación de los residuos: parte en 0,96 con 1 hora de rezago, baja de forma gradual y se acerca a cero recién alrededor de las 20 horas de rezago. Como la dependencia dura cerca de un día, el bootstrap remuestrea días completos y no horas sueltas.



3. Validación y preparación

El conjunto de datos se dividió temporalmente en entrenamiento (2015-2017, 26.108 observaciones) y prueba o test (año 2018, 8.758 observaciones).

Dentro del entrenamiento se aplicó una validación cruzada temporal de 4 bloques (folds) con ventana expansiva y 1 día de purga entre el entrenamiento y la validación para respetar el horizonte de 24 horas. Para garantizar la ausencia de fuga de información, cualquier transformación o imputación por mediana se realizó exclusivamente dentro de los datos de ajuste de cada fold y luego se aplicó a los datos de validación. Se fijó la semilla global en 2026 para asegurar la reproducibilidad total.

La Figura B4 muestra la demanda diaria promedio del periodo de entrenamiento. Las líneas punteadas marcan el inicio de los cuatro folds de validación (uno por trimestre de 2017) y la franja gris corresponde al año 2018, que se mantuvo apartado hasta la evaluación final. El nivel de la serie se mantiene estable entre 2015 y 2017, sin una tendencia marcada, lo que respalda usar los años anteriores para predecir 2018.

4. Modelos

Se ajustaron y compitieron las siguientes familias de modelos:

1. Baseline (Referencia 1): Promedio histórico agrupado por hora del día y día de la semana.
2. Ingenuo Semanal (Referencia 2): Valor directo de la demanda consumida exactamente una semana atrás.
3. OLS: Regresión lineal con interacciones entre la hora y el tipo de día.
4. Regularizados (Ridge, Lasso y Elastic-Net): Ajustados mediante glmnet evaluando una grilla de 60 valores de lambda.
5. GAM (Modelos Aditivos Generalizados): Splines cíclicos para la hora y el día del año, probando 5 y 10 funciones base (nudos).
6. Árbol de Decisión: Evaluando parámetros de complejidad entre 0,0001 y 0,01.
7. Random Forest: Ajustando 300 árboles y variando las variables elegidas al azar por corte (mtry = 3, 6, 9).
8. Boosting: Evaluando combinaciones de profundidad (3 y 5), tasa de aprendizaje (0,05, 0,1 y 0,2) y hasta 1.000 árboles.
9. Averaging: Promedio simple de las predicciones de los tres mejores modelos individuales.



El Anexo B también muestra cómo se comportaron algunos de estos modelos. En la Figura B5, con penalizaciones pequeñas, Ridge, Lasso y Elastic-Net tienen el mismo error de validación que el OLS (cerca de 2.600 MW), y al aumentar λ el error solo crece: como hay muchas más observaciones que coeficientes (más de 17.000 frente a 71 en cada fold), el OLS casi no sobreajusta y la penalización tiene poca varianza que reducir. La Figura B6 muestra cómo el lasso lleva los coeficientes a cero a medida que aumenta la penalización (hacia la izquierda del gráfico). Con la penalización más fuerte que todavía acepta la regla de 1 error estándar (λ.1se ≈ 73,2; línea punteada) quedan en cero 33 de los 71 coeficientes, todos variables indicadoras de hora, día o mes, o interacciones hora × tipo de día, mientras que los siete predictores numéricos se mantienen. La Figura B7 presenta las curvas estimadas por el GAM: los efectos más grandes son los de la hora (en días laborables, unos 7.500 MW de diferencia entre la madrugada y el mediodía) y de la demanda de hace 24 horas, mientras que el día del año mueve la predicción en menos de 1.000 MW, con máximos en invierno y en verano. Por último, la Figura B8 muestra un árbol de regresión simplificado (cp = 0,01), solo para ilustrar cómo decide: el primer corte separa las horas 0 a 7 del resto del día y los siguientes usan la demanda de hace 24 horas y el tipo de día. El árbol evaluado en la validación cruzada (cp = 0,001) es bastante más profundo.

5. Comparación, test y subgrupos

En la validación cruzada temporal, el modelo que logró el menor RMSE promedio fue el Random Forest (2.422 MW, con un error estándar entre folds de 110 MW). Aplicando la regla de 1 error estándar (umbral de parsimonia fijado en 2.532 MW), ningún modelo más simple logró superar a Random Forest, por lo que fue seleccionado como el sistema definitivo y congelado.

La Figura B9 resume esta comparación: cada punto es el RMSE promedio de los 4 folds, la barra abarca ±1 error estándar y la línea punteada marca el umbral de 2.532 MW. Solo Random Forest, Averaging y Boosting quedan por debajo del umbral y, de ellos, Random Forest es el más simple. Los modelos lineales y el GAM se ubican cerca de 2.600 MW, unos 180 MW por sobre Random Forest, y el baseline queda último con 2.909 MW.

Resultados en la apertura única del conjunto de Test (Año 2018):

- Sistema Seleccionado (Random Forest, mtry=3):
    - RMSE global: 2.361 MW (Intervalo de confianza 95% por bootstrap: [2.178 MW ; 2.558 MW]).
    - Error absoluto medio (MAE): 1.642 MW | R cuadrado: 0,740.
- Modelo Baseline (Referencia):
    - RMSE global: 2.826 MW (Intervalo de confianza 95%: [2.646 MW ; 3.024 MW]).



- Diferencia y Mejora:
    - El Random Forest logró una reducción directa del error de 465 MW, representando una mejora del 16,4% respecto al baseline (Intervalo de confianza 95% del porcentaje de mejora: [12,1% ; 20,8%]). Al no incluir el cero, se confirma que la mejora es estadísticamente significativa y real.
- Subgrupo de Días No Laborables (Fines de semana y festivos):
    - El error del Random Forest subió a 2.709 MW (MAE de 1.925 MW), representando una mejora del 14,1% respecto al baseline en ese mismo subgrupo (3.153 MW).
- Intervalo de Predicción Empírico:
    - Construido con los cuantiles al 95% de los residuos de validación (ancho promedio de 10.810 MW), alcanzó una cobertura real en el test del 95,2%, cumpliendo con la fiabilidad prometida

La Figura B10 muestra siete días del test. El Random Forest reproduce la forma diaria de la demanda y, en general, se acerca más a la demanda real que el baseline. La demanda real queda dentro de la banda del 95% en la mayoría de las horas; las salidas se concentran en un día de demanda inusualmente baja y en el día de mayor demanda (máximo cercano a 39.800 MW), que el modelo subestima. La Figura B11 compara el RMSE del test mes a mes: el Random Forest tiene menor error que el baseline en los 12 meses de 2018. La ventaja es mayor entre diciembre y abril (más de 500 MW por mes) y casi desaparece en mayo y octubre (menos de 150 MW).

6. Interpretación, límites y recomendación

El análisis de importancia por permutación en el Random Forest confirmó que la hora del día y la demanda de hace 24 horas son las dos variables con mayor capacidad explicativa del sistema: al permutar cualquiera de ellas, el error cuadrático aumenta alrededor de tres veces más que al permutar la variable siguiente, la demanda de hace una semana (Figura B12). El gráfico de dependencia parcial (PDP e ICE, Figura B13) muestra el efecto propio de la hora: un valle de bajo consumo durante la madrugada (alrededor de las 04:00 horas), un aumento marcado entre las 06:00 y las 09:00 horas y un nivel casi constante, cercano a 30.300 MW, desde las 10:00 hasta las 21:00 horas. Los dos máximos diarios de la demanda (entre las 11:00 y las 13:00 horas y entre las 20:00 y las 21:00 horas) no aparecen en el PDP porque esa forma entra al modelo, en gran parte, a través de la demanda de hace 24 horas, que repite el mismo ciclo diario; se observan en el perfil horario (Figura B1) y en la curva de la hora del GAM (Figura B7).

Límites operacionales:

El modelo no incorpora información meteorológica futura (como temperatura o radiación pronosticada), por lo que su desempeño se degrada levemente durante olas de calor en verano o frentes fríos extremos en invierno. Esto es coherente con la Figura B11: en el test, los mayores errores mensuales del Random Forest se dieron en diciembre, enero y febrero, seguidos de junio.

Recomendación accionable:

Se recomienda implementar el modelo Random Forest para la programación del despacho eléctrico diario, estableciendo un protocolo de reentrenamiento mensual continuo para mitigar el desgaste por deriva de datos (data drift) y mantener alertas operativas especiales durante días festivos nacionales.

7. Tabla 1: Resultados de validación cruzada temporal

Modelo	Familia	Hiper Parámetros	RMSE (MW)	DE RMSE (folds)	MAE (MW)	R2	RMSE subgrupo (no lab.)	vs Baseline (global)	vs Baseline (subgrupo)
Baseline	Referencia	promedio_hora_dia	2.909	196	2.201	0,588	2.960	+0.0%	+0.0%
OLS	Lineal	ols	2.605	179	1.885	0,669	2.588	-10.5%	-12.6%
Ridge	Regularizado	alpha=0.0 | lambda=186.7	2.597	180	1.878	0,672	2.571	-10.7%	-13.1%
Elastic-net	Regularizado	alpha=0.5 | lambda=11.2	2.601	179	1.884	0,670	2.581	-10.6%	-12.8%
Lasso	Regularizado	alpha=1.0 | lambda=4.41	2.602	179	1.883	0,670	2.582	-10.6%	-12.8%



GAM	Flexible	k=5	2.615	165	1.894	0,667	2.794	-10.1%	-5.6%
Árbol	Árbol	cp=0.001	2.767	195	1.975	0,628	2.876	-4.9%	-2.8%
Random Forest	Ensemble	mtry=3	2.422	110	1.686	0,713	2.643	-16.7%	-10.7%
Boosting	Ensemble	prof=5 | shr=0.05 | arboles=300	2.498	161	1.800	0,694	2.617	-14.1%	-11.6%
Averaging	Ensemble	RF + Boost + Ridge	2.439	148	1.730	0,709	2.555	-16.2%	-13.7%

Tabla 1: Resultados comparativos de los 11 modelos evaluados en validación cruzada temporal (promedios de 4 folds).



Referencias

[1] ENTSO-E / Red Eléctrica de España. (2018). *Hourly energy demand, generation and weather dataset*. Kaggle Repository. https://www.kaggle.com/datasets/nicholasjhana/energy-consumption-generation-prices-and-weather

[2] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springerb https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf

Anexos

Anexo A. Diccionario de variables

- demanda: Demanda eléctrica real de la hora expresada en megavatios (MW). Variable respuesta.
- hora / dia_semana / dia_año: Variables de calendario local que capturan el ciclo diario, semanal y la estacionalidad anual.
- no_laborable: Variable binaria (1 si es sábado, domingo o festivo nacional en España; 0 en caso contrario).
- demanda_lag24: Demanda real observada en la misma hora del día anterior (MW).
- demanda_lag168: Demanda real observada en la misma hora de la semana anterior (MW).
- demanda_prom24: Promedio móvil del consumo de las últimas 24 horas (MW).
- precio_lag24: Precio del mercado diario 24 horas antes (€/MWh).
- solar_lag24 / eolica_lag24 / gas_lag24: Generación eléctrica registrada 24 horas antes por fuente solar, eólica y gas fósil (MW).

Anexo B. Gráficos del análisis

Los gráficos se generaron con el código del proyecto en R a partir de los datos de ENTSO-E y Red Eléctrica de España [1], y se numeran según el orden en que se citan en el informe.

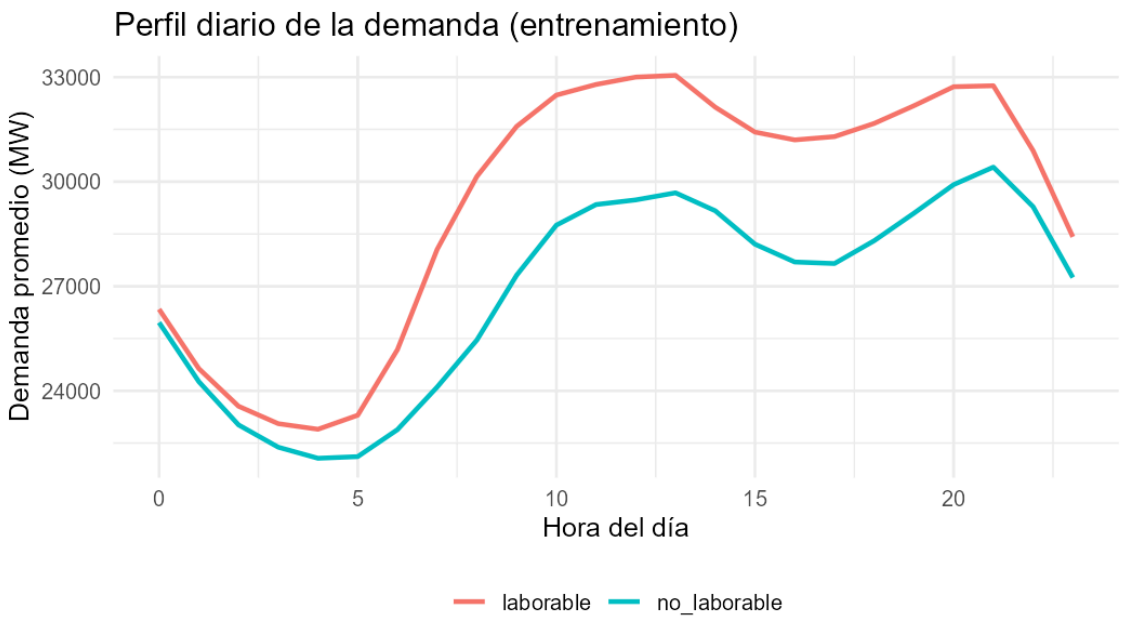


Figura B1: Perfil diario de la demanda promedio por hora en el entrenamiento (2015-2017), en días laborables y no laborables.

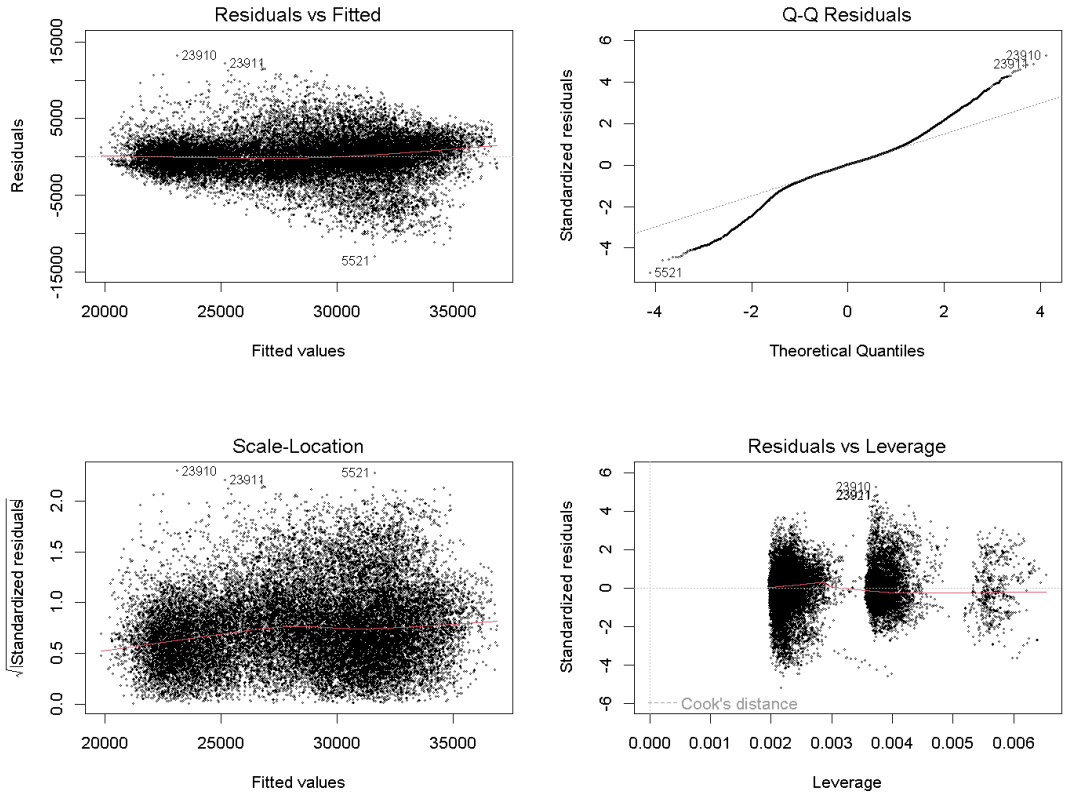


Figura B2: Diagnóstico de los residuos del modelo OLS: residuos contra valores ajustados, gráfico Q-Q, escala-ubicación y residuos contra apalancamiento.

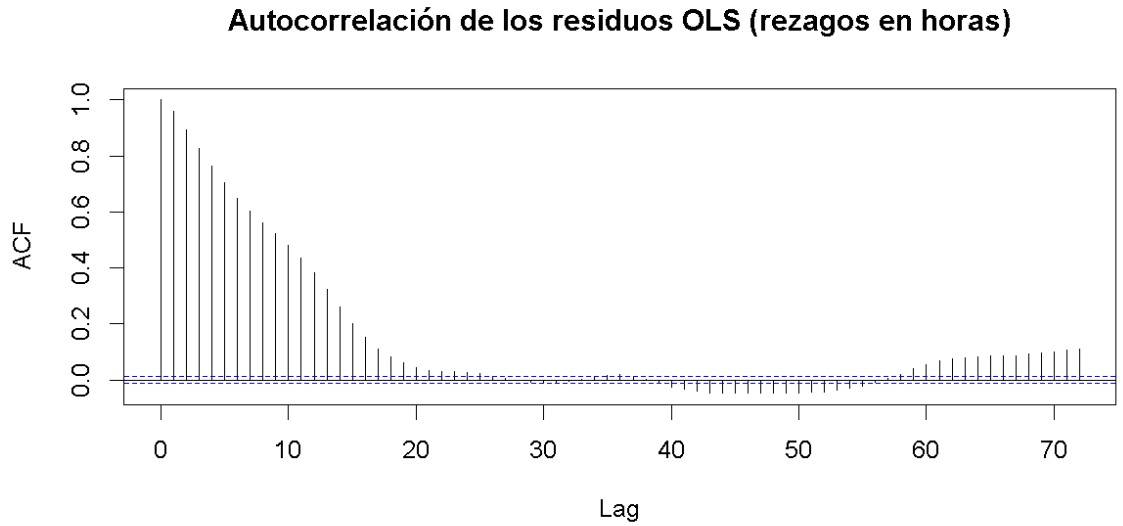


Figura B3: Autocorrelación de los residuos del modelo OLS hasta 72 horas de rezago.

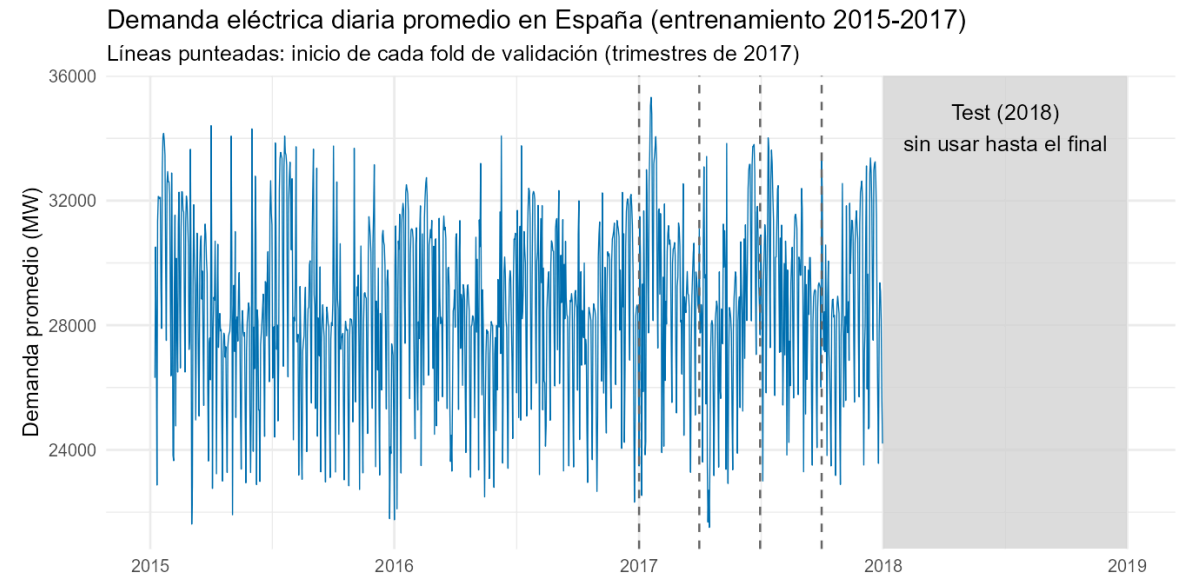


Figura B4: Demanda diaria promedio en el entrenamiento, con el inicio de cada fold de validación (líneas punteadas) y el año de test reservado (franja gris).

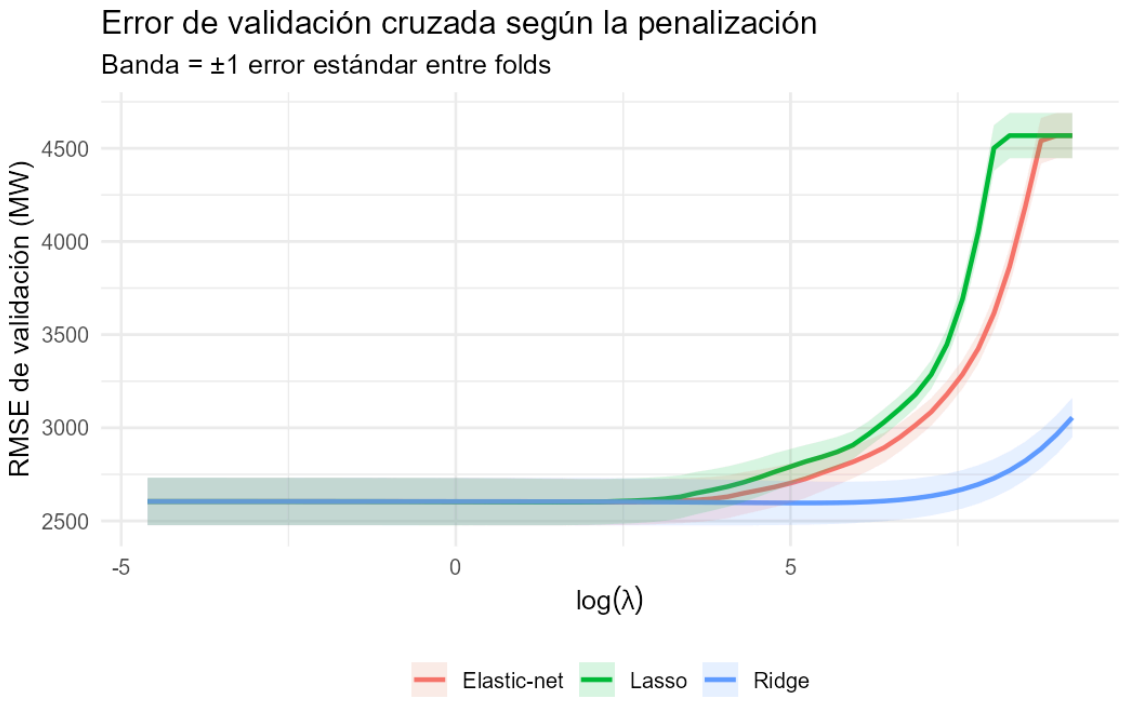


Figura B5: RMSE de validación cruzada de Ridge, Lasso y Elastic-Net según la penalización, con una banda de ±1 error estándar entre folds.

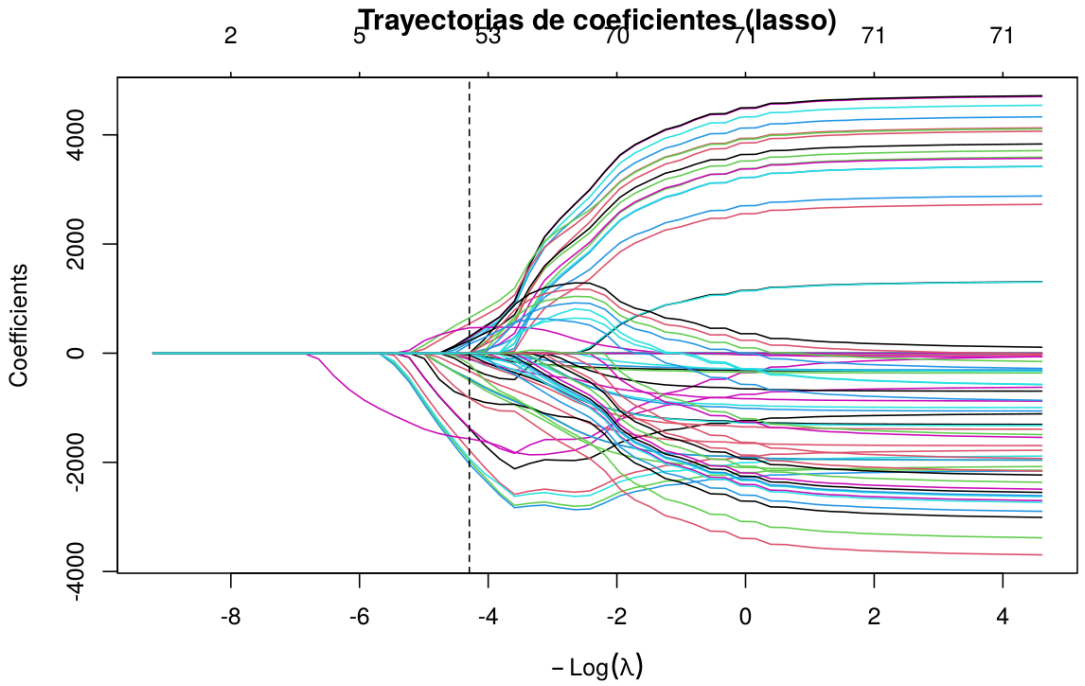


Figura B6: Trayectorias de los coeficientes del lasso. Hacia la izquierda aumenta la penalización; el eje superior indica cuántos coeficientes siguen distintos de cero y la línea punteada marca λ.1se ≈ 73,2.

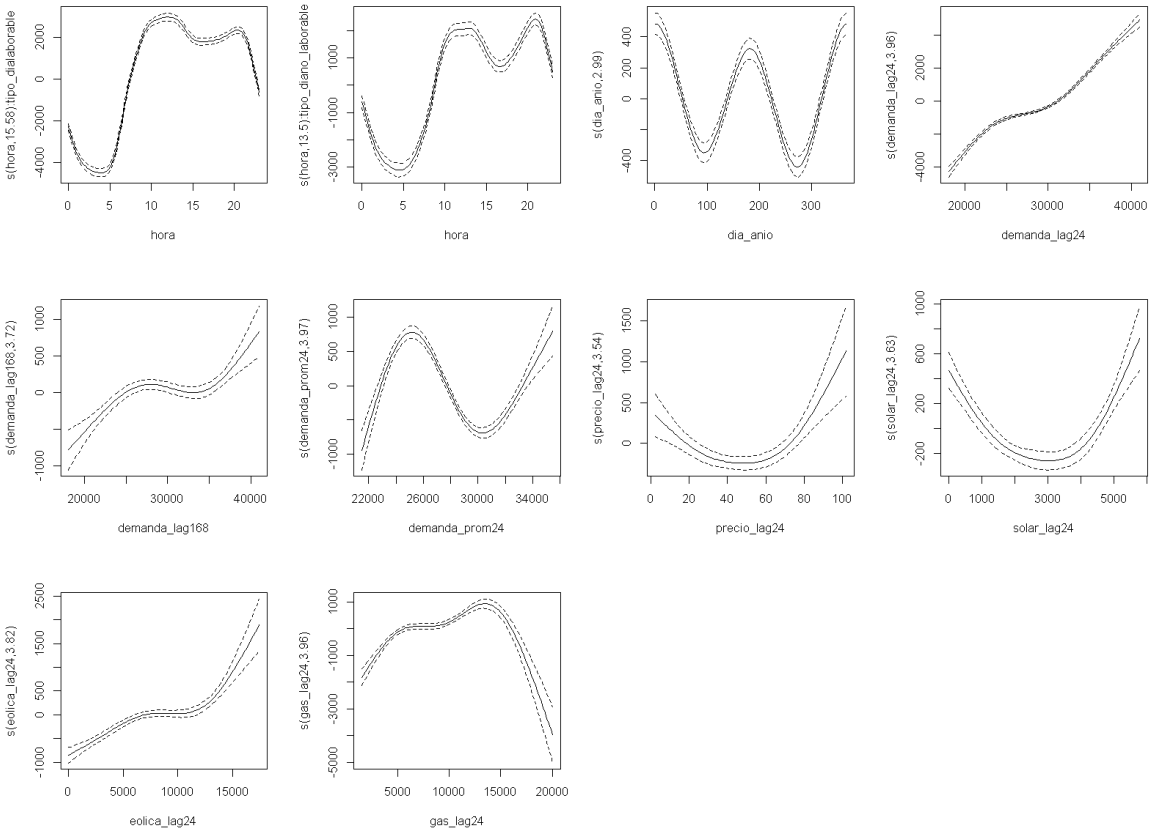


Figura B7: Efectos estimados por el GAM para cada predictor, con bandas de ±2 errores estándar (cada panel tiene su propia escala vertical).

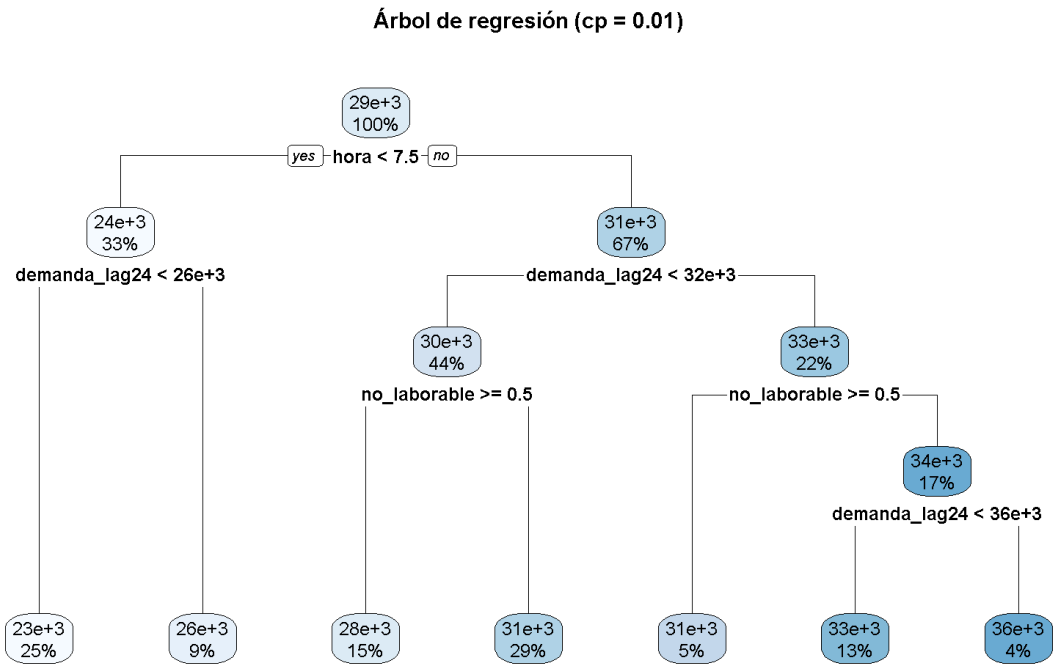


Figura B8: Árbol de regresión simplificado (cp = 0,01) ajustado con todo el entrenamiento. Cada nodo indica la demanda promedio (MW) y el porcentaje de observaciones.

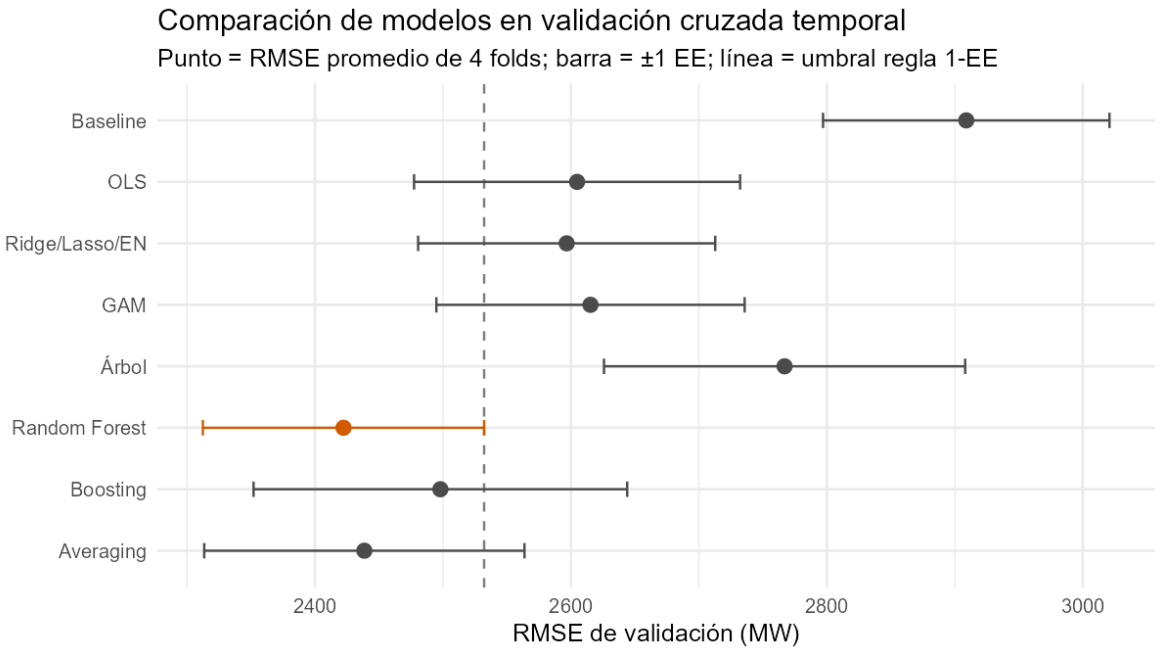


Figura B9: RMSE promedio de validación cruzada por modelo (punto) con ±1 error estándar (barra); la línea punteada marca el umbral de la regla de 1 error estándar (2.532 MW).

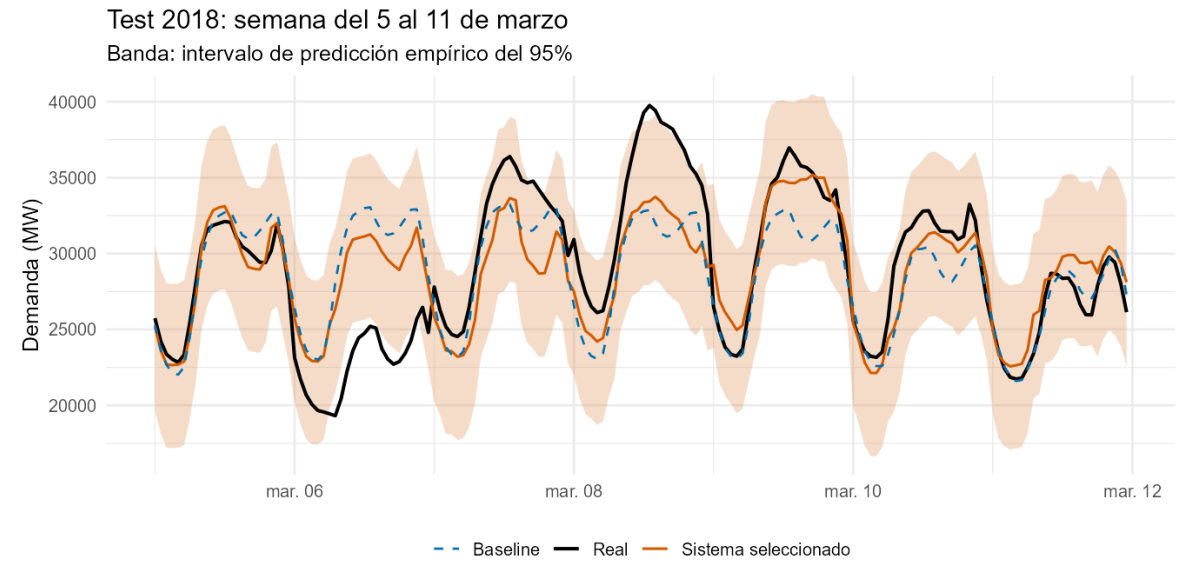


Figura B10: Demanda real y predicciones del Random Forest y del baseline entre el 5 y el 11 de marzo de 2018 (periodo de test), con el intervalo de predicción empírico del 95%.

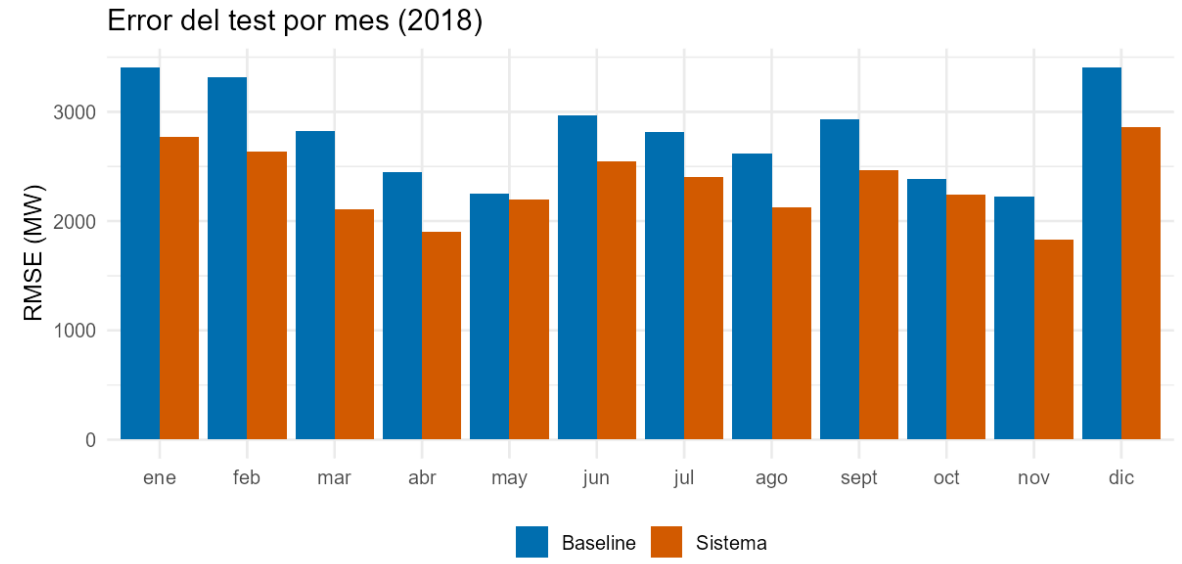


Figura B11: RMSE mensual del Random Forest (sistema seleccionado) y del baseline en el test 2018.

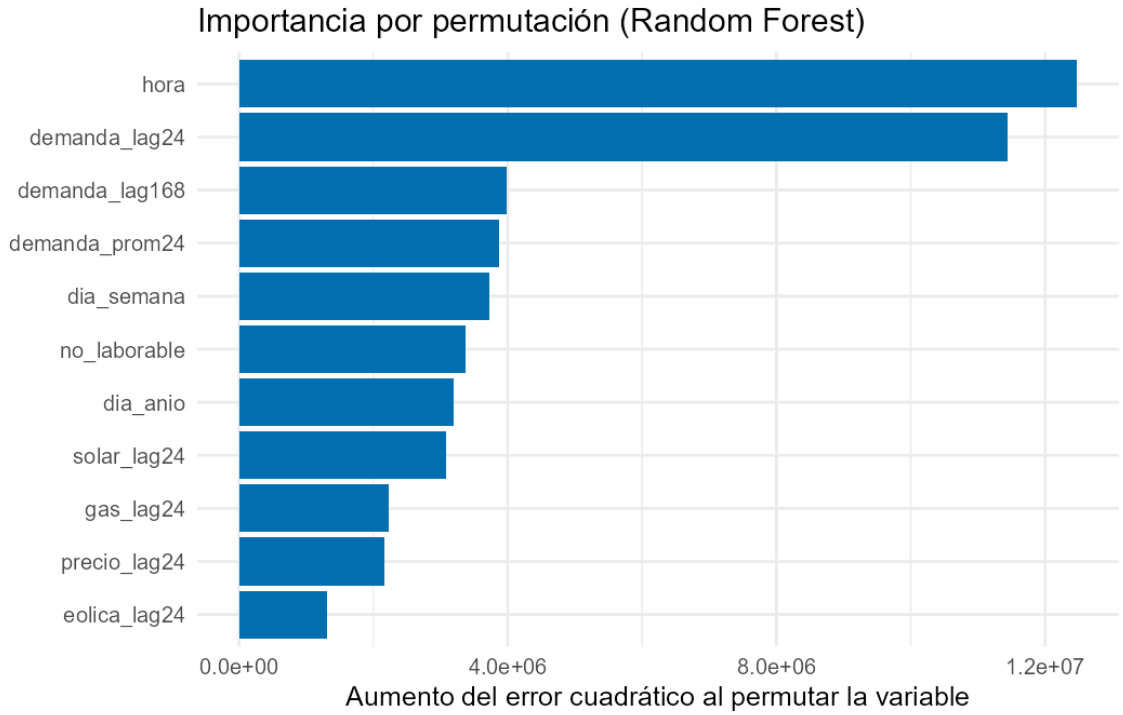


Figura B12: Importancia por permutación de las variables en el Random Forest (aumento del error cuadrático al permutar cada variable).

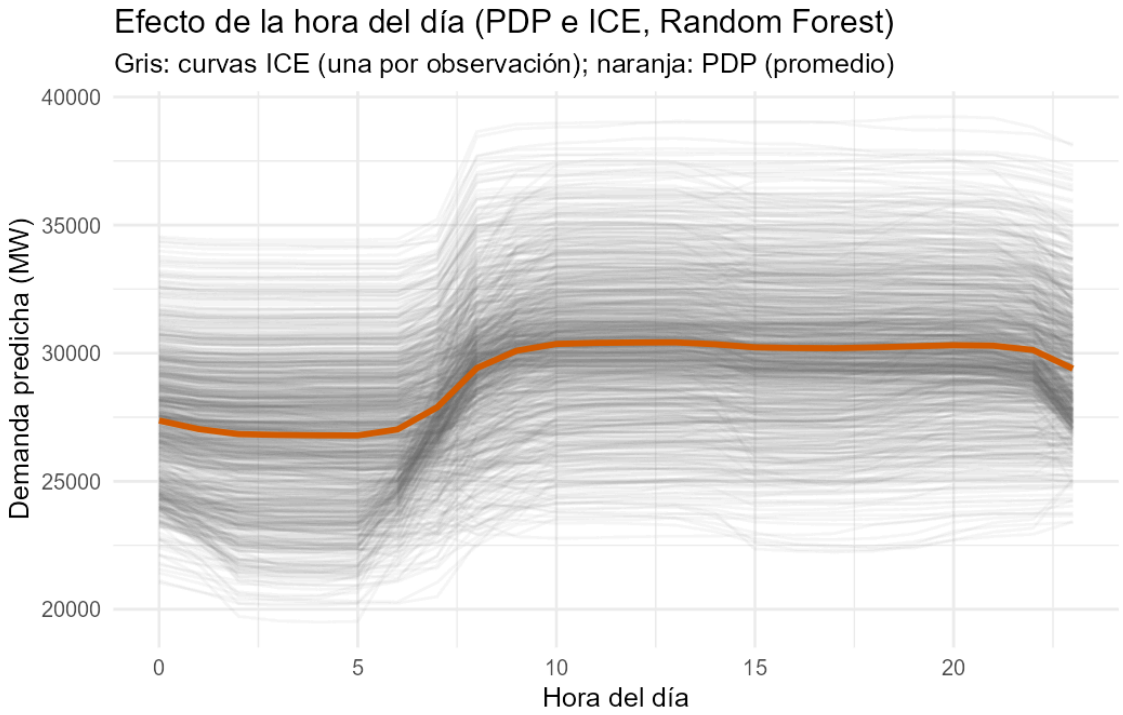


Figura B13: Efecto de la hora del día en el Random Forest: dependencia parcial (PDP, naranja) y curvas ICE (gris).