INGENIERÍA INDUSTRIAL

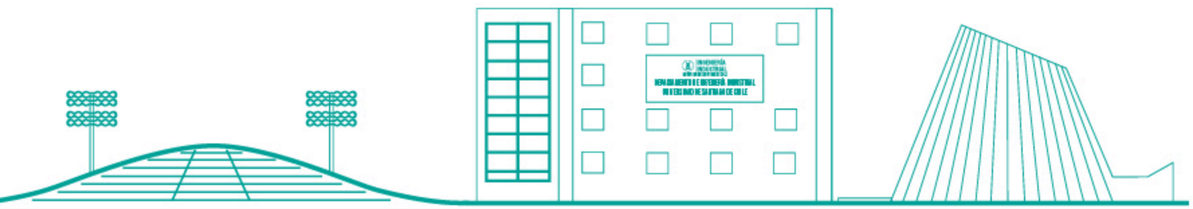
UNIVERSIDAD DE SANTIAGO DE CHILE

PROYECTO INTEGRADOR REGRESIÓN

Predicción del consumo eléctrico en España

Antonia Carvajal
Héctor Ortiz
Martina Pinto
Cristian Ramos
Amanda Toro

Estadística Aplicada · Ingeniería Industrial



1. El problema conduce a una decisión

Qué se predice, quién actúa y por qué el error tiene consecuencias.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Problema y Usuario

Usuario de la predicción: Operador del Sistema Eléctrico (Red Eléctrica de España / REE).

Decisión apoyada: Programación del despacho térmico y reserva fría a t + 24 h.

Unidad de análisis: Una hora individual del sistema eléctrico nacional.

Población objetivo: Consumo total del sistema eléctrico español (2015–2018).

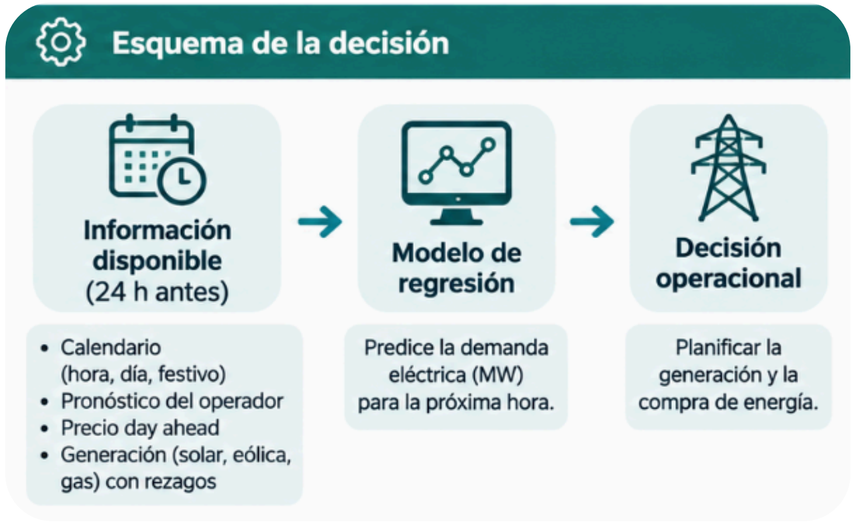
Respuesta y Costo del Error

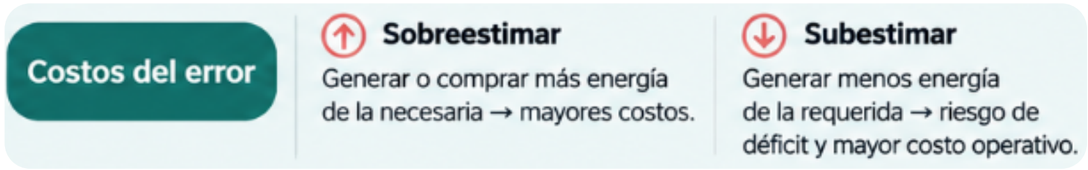
Respuesta continua (Y): Demanda real observada (total load actual, en MW).

Horizonte de predicción: Exactamente 24 horas de anticipación.

Costo de Sobreestimar: Encendido innecesario de térmicas (costos operacionales elevados y emisiones).

Costo de Subestimar: Riesgo de desabastecimiento, apagones parciales o compras spot carísimas.





2. El dataset debe ser pertinente

La elección se justifica por la decisión, no por disponibilidad.

Fuente

Fuente: Plataforma oficial ENTSO-E / Red Eléctrica de España (Kaggle Dataset).

Período: 1 de enero de 2015 al 31 de diciembre de 2018 (35.064 horas).

Tamaño utilizable: n = 34.866 observaciones tras limpiar faltantes en Y y rezago semanal.

Pertinencia

Disponibilidad al corte: Solo variables conocidas a t - 24 h (calendario y rezagos ≥ 24 h).

Alternativas descartadas: Generación solar/eólica/gas contemporánea (causaría trampa/leakage directo).

Integridad: 8 verificaciones de auditoría automatizadas aprobadas (8/8 TRUE).

Justificación: Se seleccionó este conjunto de datos porque contiene registros horarios que permiten analizar patrones de demanda eléctrica y comparar modelos de regresión bajo una validación temporal.
Restricción: Se excluyen las variables que no estarían disponibles al momento de realizar la predicción, evitando fuga de información.

3. EDA e Inferencia

Muestre hallazgos que cambiaron decisiones y una relación estimada.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Calidad

Faltantes: 36 NAs en Y (0,1%), eliminados por no observados (MCAR).

Influencia: Distancia de Cook máxima = 0,00145 (sin outliers influyentes).

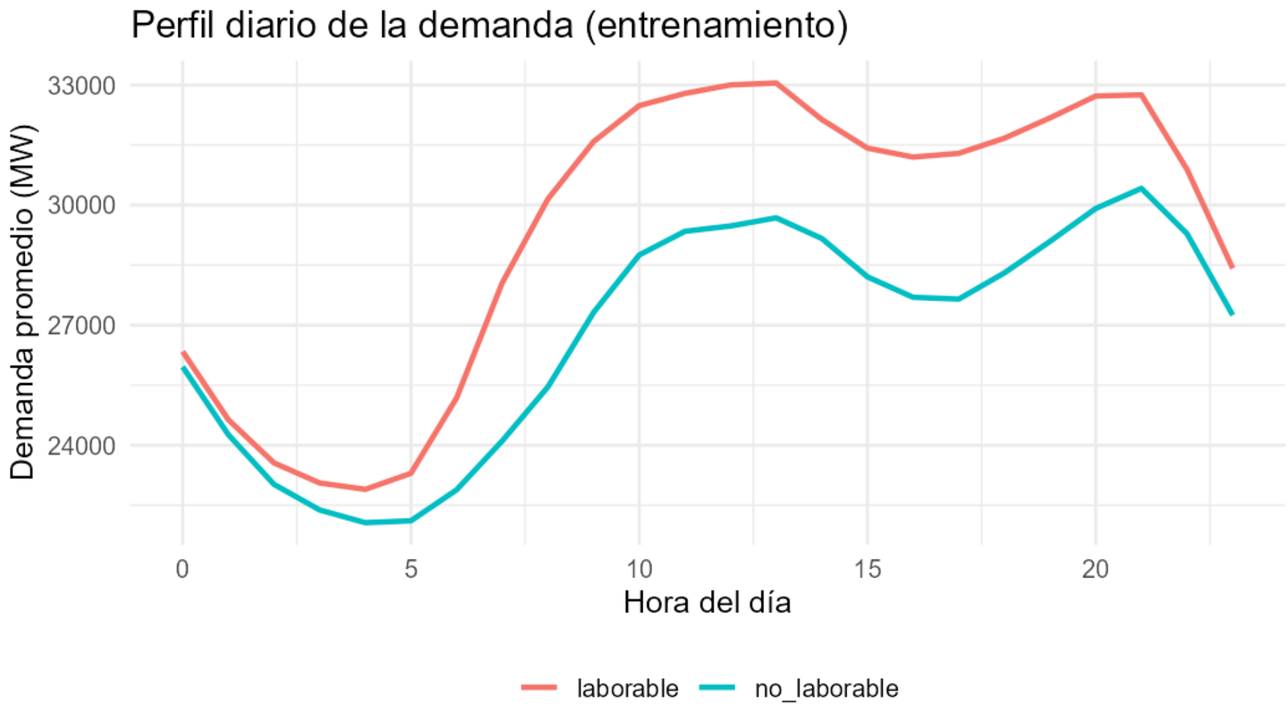
Multicolinealidad: VIF máximo = 3,77 en demanda_lag24 (VIF < 10, OK).

Relación Estimada

Demanda lag 24 h: β = +0,290 MW ($p < 2\times10^{-16}$). Efecto +1 DE (+4.541 MW) = **+1.317 MW (4,61% media)**. Significativo Y Relevante.

Precio lag 24 h: β = +10,8 ($p = 2{,}29\times10^{-10}$). Efecto +1 DE = **+153 MW (0,54% media)**. IC Boot 95%: [-3,23 ; 21,70] (incluye 0). Significativo por n alto, PERO NO RELEVANTE.

Supuestos: Autocorrelación fuerte (r = 0,96; DW p < 0,001) exige **Bootstrap por bloques diarios**.



4. La evaluación representa el uso futuro

Mismos folds, test intacto, sin fuga de información.

Partición

Entrenamiento + CV: Años 2015–2017 (26.108 observaciones | 74,9%).

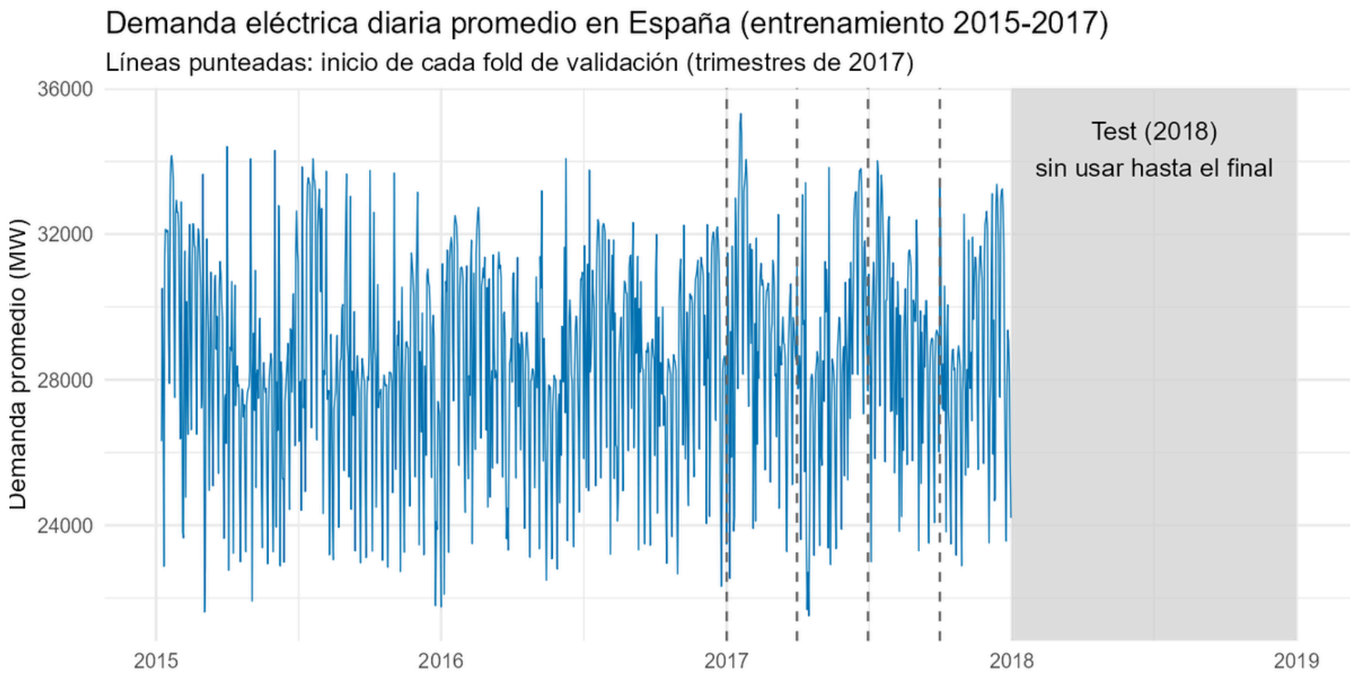
Test Intacto (Cerrado): Año 2018 completo (8.758 observaciones | 25,1%). No se tocó hasta el final.

CV y Preparación

4 Folds crecientes: Cada fold valida un trimestre de 2017 y entrena con el pasado acumulado.

Purga de 1 día: Evita solapamiento entre el entrenamiento y la ventana a t + 24 h.

Sin Fuga: Medianas de imputación calculadas estrictamente dentro del ajuste de cada fold. Semilla: 2026.



5. Compare familias distintas

Qué aporta cada familia y qué hiperparámetros la controlan.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Lineal y Regularización

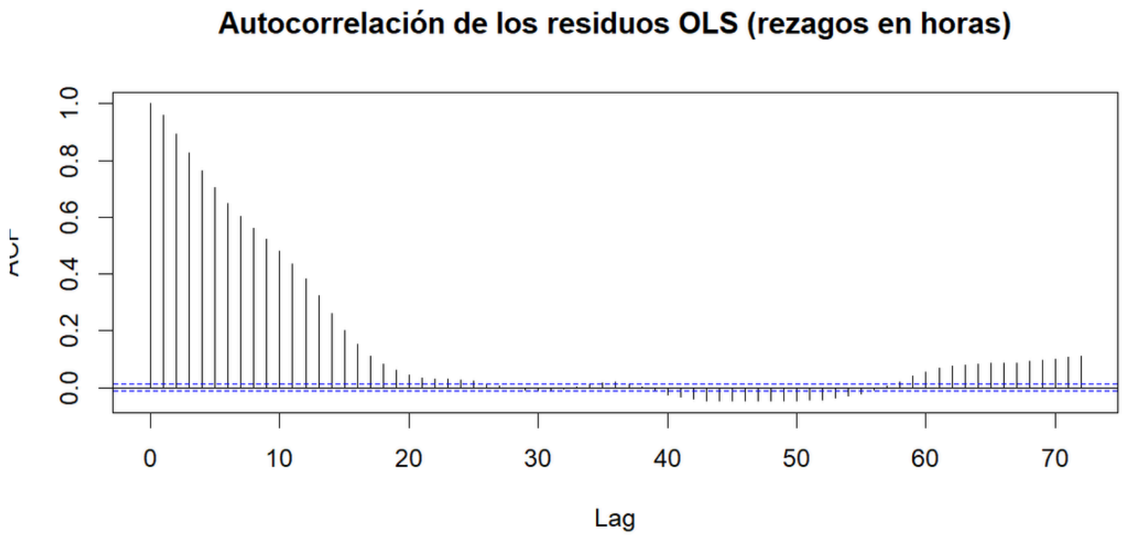
OLS: Modelo base lineal con factores de hora, día y mes + interacciones.

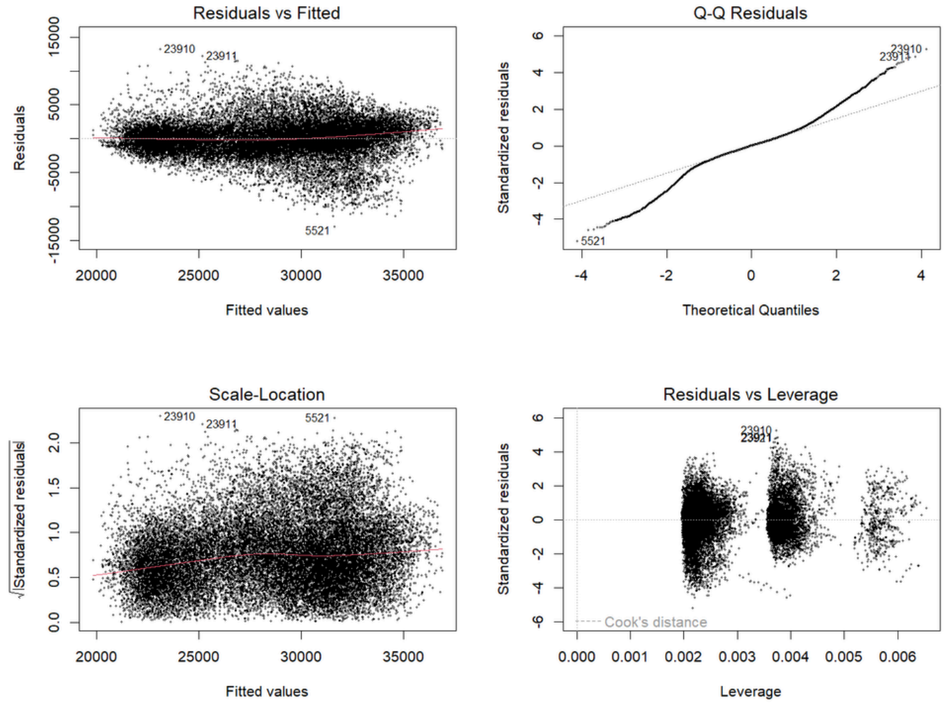
Ridge, Lasso, Elastic-Net: Evaluados con glmnet sobre grilla de 60 valores de λ y α ∈ {0; 0,5; 1}. Controlan la complejidad lineal.

Flexibles y Ensembles

GAM (Splines): Captura no linealidad con splines cíclicos para hora y día del año (k = 5, 10).

Árbol, Random Forest, Boosting: Capturan interacciones complejas. RF (mtry = 3, 6, 9; 300 árboles), GBM (profundidad 3, 5; shrinkage 0.05, 0.1, 0.2) y Averaging.





#SOMOSUSACH

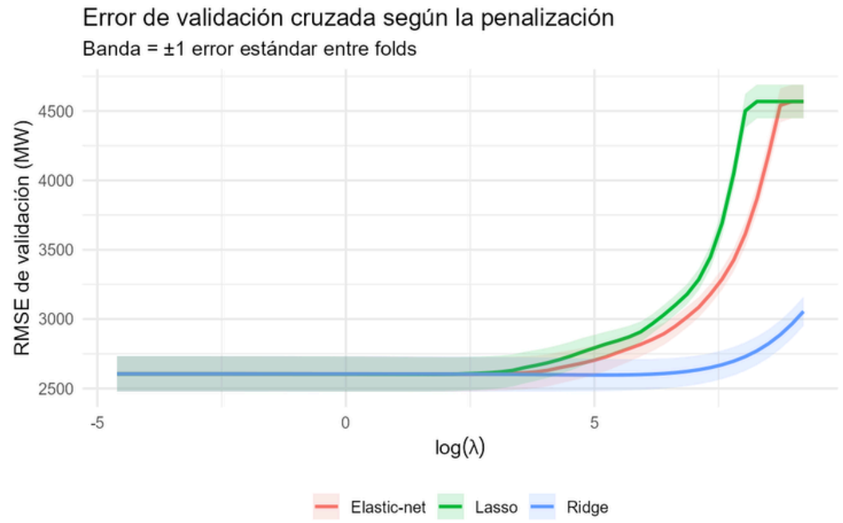
6. Comparar con incertidumbre

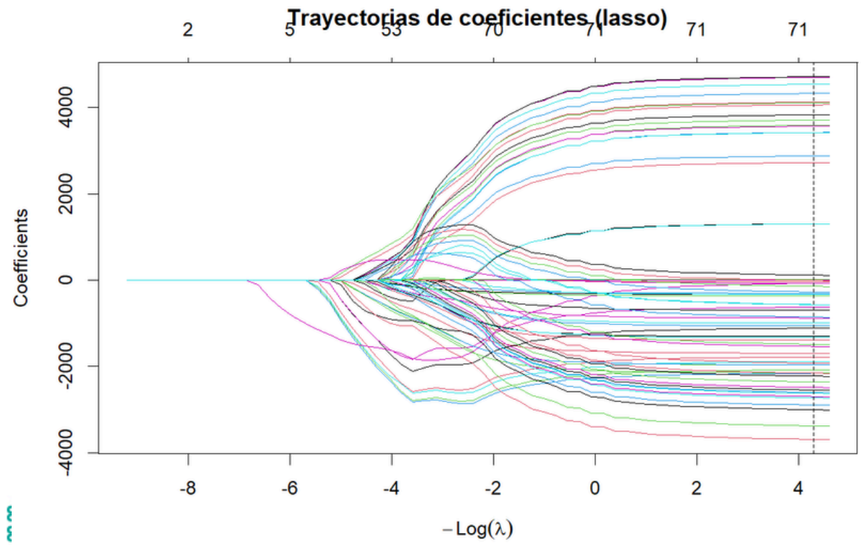
La mejor cifra puntual no basta: baseline y variabilidad entre folds.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Modelo	Familia	RMSE (MW)	DE RMSE	MAE (MW)	R^2	vs Baseline
Baseline	Referencia	2.909	196	2.201	0,588	0,0%
Ingenuo semanal	Referencia	3.757	185	2.642	0,314	+29,2%
OLS	Lineal	2.605	179	1.885	0,669	-10,5%
Ridge / Lasso / EN	Regularizado	2.597	180	1.878	0,672	-10,7%
Random Forest (mtry=3)	**Ensemble**	**2.422**	**110**	**1.686**	**0,713**	**-16,7%**
Boosting (prof=5)	Ensemble	2.498	161	1.800	0,694	-14,1%

Estabilidad: Random Forest logra el menor RMSE (2.422 MW) y la menor desviación estándar entre folds (110 MW). Umbral regla 1-EE = 2.532 MW. Ningún modelo más simple entra en la tolerancia → **Se Congela Random Forest**.





7. Interpretar el modelo

Patrones predictivos, no causalidad.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Importancia

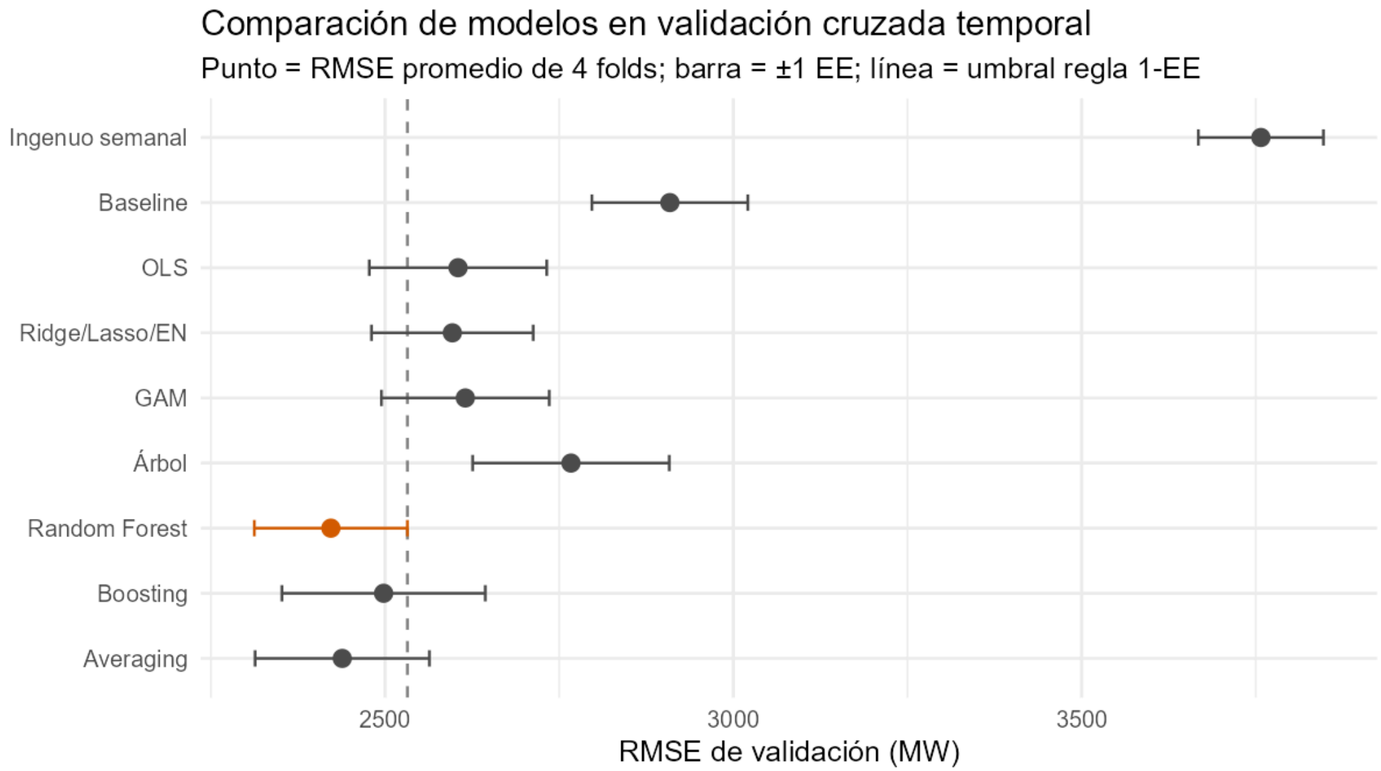
1. **Hora del día:** Predictor #1 dominante en la variación del consumo.
2. **Demanda lag 24 h:** Inercia del nivel de consumo del día anterior.
3. **Demanda lag 168 h:** Efecto estacional semanal.

Efectos Parciales

Valle nocturno: Mínimo pronunciado de demanda a las 04:00–05:00 h.

Picos diarios: Máximos a las 11:00 h y a las 20:00 h (actividad industrial y doméstica).

Cautela Causal: Refleja asociación predictiva, no un efecto causal directo intervenible.



8. El test evalúa un sistema congelado

Una sola evaluación final del sistema elegido (Año 2018).

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

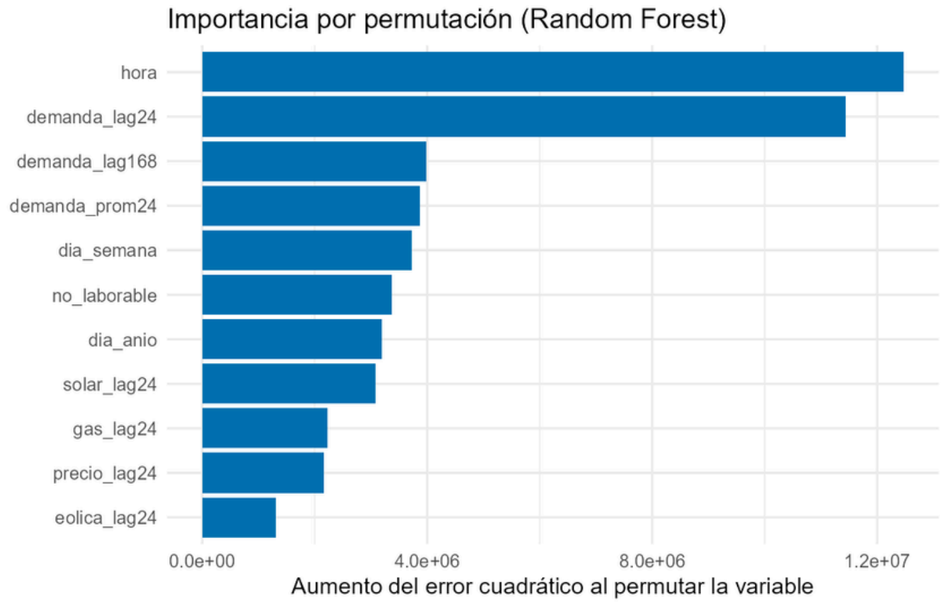
Sistema final (Random Forest)

- Modelo e hiperparámetros

1. mtry = 3
2. 300 arboles
3. min.node.size = 5

- Modelo e hiperparámetros

1. Imputacion por mediana.
2. Medianas calculadas con entrenamiento 2025- 2027
3. Predictores y configuracion definidos antes del test



Test (2018)

- Error e intervalos de predicción

2.361 MW

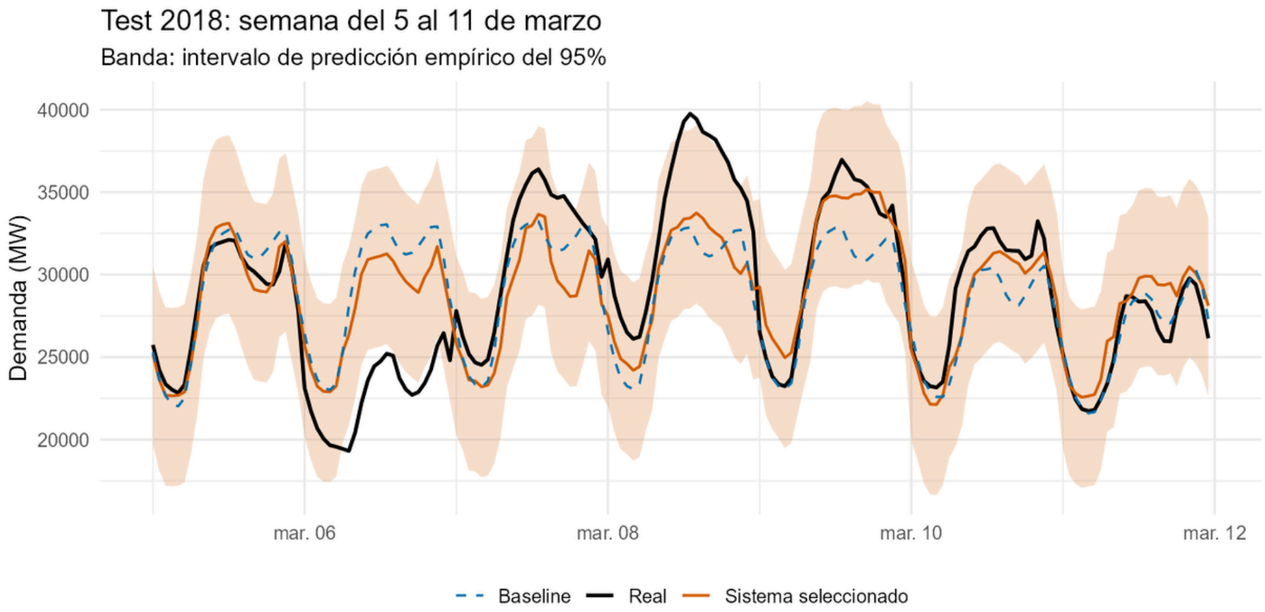
RMSE

1. MAE: 1.642 MW
2. $R^{2:}$ 0.740
3. Cobertura IC preduccion 95%: 95.2%
4. Ancho promedio: 10.810MW

- Mejora vs baseline

16.4%

1. Baseline RMSE: 2.826MW
2. IC Boorstrap 95%: [12.1% ; 20.8%]



#SOMOSUSACH

9. Errores y subgrupos

Dónde y para quién falla el modelo.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Análisis de Residuos

Heterocedasticidad: Mayor dispersión de errores en horas pico de mediodía y tarde.

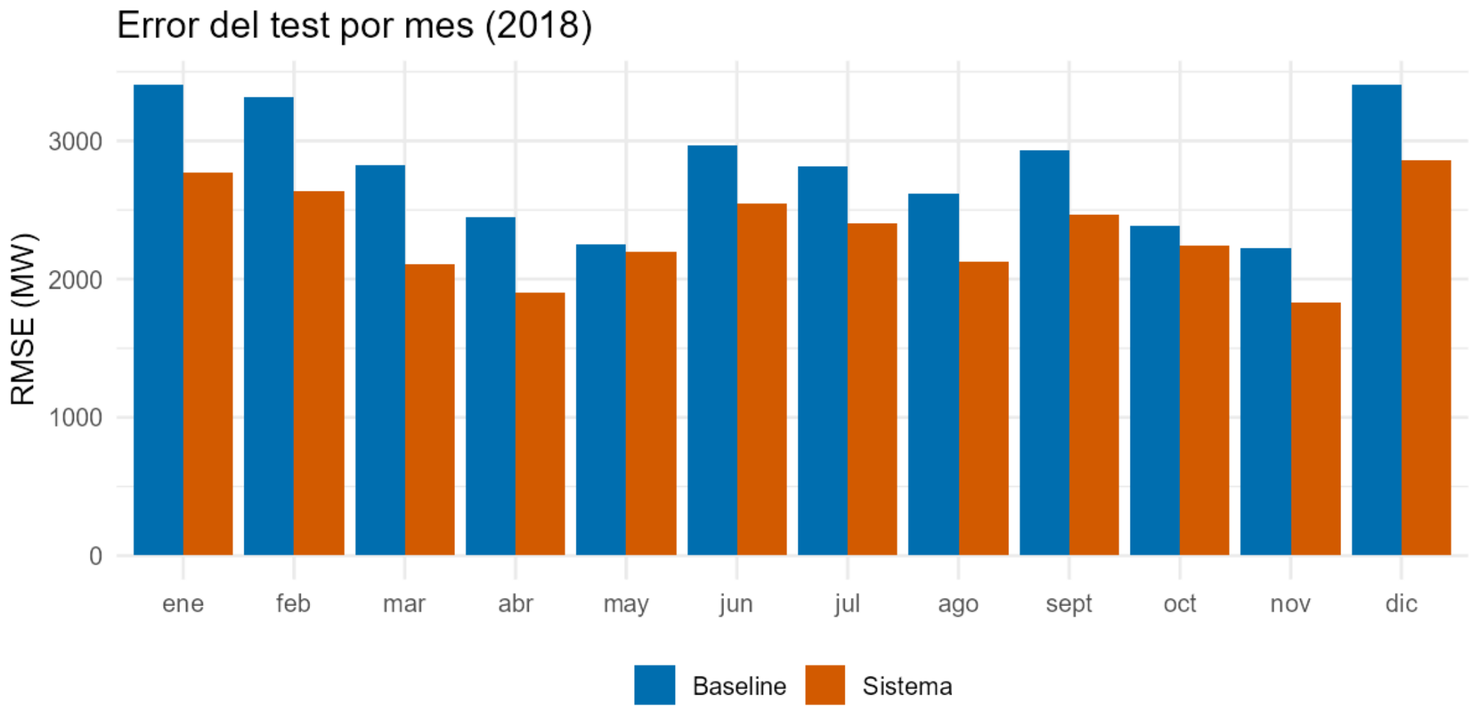
Distribución: Residuos aproximados a la normalidad en el centro, pero con colas pesadas en días extremos.

Subgrupo Crítico: Días No Laborables

RMSE Subgrupo: Aumenta a **2.709 MW** (vs. 2.361 MW global).

R^2 Subgrupo: Cae a 0,587 durante fines de semana y festivos nacionales.

Causa: Apagón industrial y patrones de consumo muy irregulares en días de descanso.



10. Recomendación y monitoreo

Decisión accionable con límites explícitos.

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Recomendación Accionable

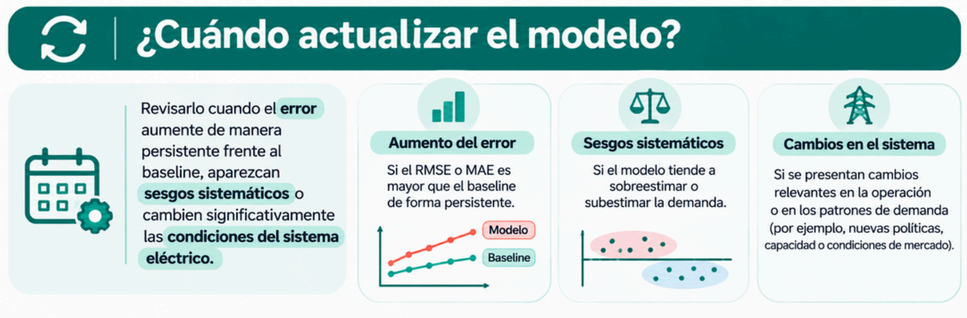
Qué usar: Implementar **Random Forest (mtry=3)** para la programación del despacho base a 24 h.

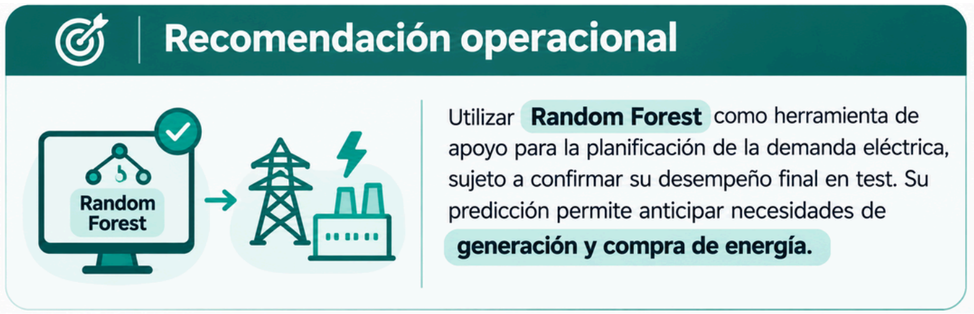
Límites: Al no incluir pronóstico meteorológico futuro, el modelo sufre en olas atípicas de calor/frío (el TSO con clima logra RMSE 389 MW).

Monitoreo y Recalibración

Indicador de Drift: Alerta si el RMSE mensual supera el umbral de 2.600 MW.

Protocolo: Reentrenamiento mensual continuo incorporando el mes más reciente para adaptar patrones estacionales.







PREGUNTAS Y DEFENSA TÉCNICA

INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

10 minutos | Todos los integrantes deben poder defender datos, código y decisiones

